

# תרגיל 1

7 באפריל 2020

דויד פונרובסקי 208504050

## 1 חימום.

### 1.1 סעיפים 1 + 2:

$$\begin{aligned} \text{proj}(u, v) &= \frac{\langle u, v \rangle}{\|u\|} \cdot \frac{u}{\|u\|} = \\ (1) \rightarrow & \frac{1}{1^2 + (-1)^2 + 2^2} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ -1 \\ 1 \\ 2 \end{bmatrix} \begin{bmatrix} 0 \\ -1 \\ 1 \\ 2 \end{bmatrix} = \frac{6}{9} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} \\ (2) \rightarrow & \frac{1}{1^2 + (-1)^2 + 1^2} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} = \frac{0}{3} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} = 0 \end{aligned}$$

### 1.2 סעיף 3:

טענה-  $\langle u, v \rangle = 0 \Leftrightarrow$  הזווית בין  $u$  ל  $v$  היא  $\pm \frac{\pi}{2}$ . ל  $u, v \in \mathbb{R}^m$ . הוכחה, נחשב את  $\langle u, v \rangle$  :

$$0 = \langle u, v \rangle = \|u\| \cdot \|v\| \cos \theta$$

מיצד שני נתון כי  $\vec{0} \neq u, v$  ולכן  $\|u\|, \|v\| > 0$  זה יכל לקרות אם ורק אם  $\cos \theta = 0$  ולכן  $\theta = \pm \frac{\pi}{2}$  (עד כדי מחזור  $2\pi$ ).

### 1.3 סעיף 4:

טענה- אם  $A \in \text{Orthonormal}$  אזי  $\|Au\|_2 = \|u\|_2$ . הוכחה: נזכיר כי  $A^t A = \mathbb{I}$ , ונקבל כי :

$$\|Au\|_2 = \left( (Au)^t Au \right)^{\frac{1}{2}} = \left( u^t A^t Au \right)^{\frac{1}{2}} = \left( u^t u \right)^{\frac{1}{2}} = \|u\|_2$$

## : SVD 2

## 2.1 סעיף 5:

נתונה לנו  $A$  ביצוג  $SVD$  כלומר  $A = UDV^T$  כאשר  $U$  ו  $V$  הן אורטונורמליות. לכן נקבל כי  $A^{-1} = (UDV^T)^{-1} = (V^T)^{-1} D^{-1} U^{-1} = VD^{-1} U^T$ . כשאשר המעבר האחרון  $U^{-1} = U^T$  נובע מכך ש  $U$  אורטונורמלית (לפי משפט). נשים לב שחישוב ההופכית על ידי דירוג  $[A|\mathbb{I}]$  (גאוס-ג'ורדן) ידרוש מאיתנו  $\mathcal{O}(n^3)$  זמן, כאשר  $n$  הוא מספר השורות (והעמודות) של  $A$ . לעומת זאת מאחר ו  $D \in diag$  ניתן לחשב את  $D^{-1}$  ב  $\mathcal{O}(n)$  ואת  $U^T$  ניתן לחשב ב  $\mathcal{O}(n^2)$ . את המימוש של  $U^T$  ניתן לשפר בכך שבמקום להחליף את  $U$  ניתן פשוט להחליף את האיטרטור, כך שבעת גישה ל  $(U^T)_{i,j}$  נקבל את  $U_{j,i}$ . זאת כמובן ב  $\mathcal{O}(1)$ .

## 2.2 סעיף 6:

נשים לב כי  $C^T = (UDV^T)^T = VD^T U^T$  אבל  $D \in diag$  ולכן  $D^T = D$  כלומר  $C^T = VDU^T$ . מכאן נקבל כי  $C^T C = VDU^T UDV^T = VD^2 V^T$ . כלומר נוכל למצוא את  $D$  ו  $V$  על ידי ליכסון של  $C^T C$ .

$$C^T C = \begin{bmatrix} 5 & -1 \\ 5 & 7 \end{bmatrix} \begin{bmatrix} 5 & 5 \\ -1 & 7 \end{bmatrix} = \begin{bmatrix} 26 & 18 \\ 18 & 74 \end{bmatrix}$$

נמצא את הערכים העצמאים:

$$\det(C^T C - \lambda \mathbb{I}) = 0 \Rightarrow (26 - \lambda)(74 - \lambda) - 18^2 = 0$$

פיתרונות של המשוואה שלעיל הם:  $\lambda = 20, 80$  ולכן  $D^2 = \begin{bmatrix} 80 & 0 \\ 0 & 20 \end{bmatrix}$  כלומר  $D = \begin{bmatrix} \sqrt{80} & 0 \\ 0 & \sqrt{20} \end{bmatrix}$ . נמצא את הוקטורים העצמאים:

$$\begin{aligned} \begin{bmatrix} 26 - 20 & 18 \\ 18 & 74 - 20 \end{bmatrix} &= \begin{bmatrix} 6 & 18 \\ 18 & 54 \end{bmatrix} = 6 \begin{bmatrix} 1 & 3 \\ 3 & 9 \end{bmatrix} \Rightarrow v = \text{normfactor} \cdot \begin{bmatrix} 3 \\ -1 \end{bmatrix} \\ \begin{bmatrix} 26 - 80 & 18 \\ 18 & 74 - 80 \end{bmatrix} &= \begin{bmatrix} -54 & 18 \\ 18 & -6 \end{bmatrix} = 6 \begin{bmatrix} -9 & 3 \\ 3 & -1 \end{bmatrix} \Rightarrow v = \text{normfactor} \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} \\ V^T &= \text{normfactor} \cdot \begin{bmatrix} 1 & 3 \\ 3 & -1 \end{bmatrix} = \begin{bmatrix} \sqrt{\frac{1}{10}} & \sqrt{\frac{9}{10}} \\ \sqrt{\frac{9}{10}} & -\sqrt{\frac{1}{10}} \end{bmatrix} \end{aligned}$$

בנוסף אנו יודעים כי  $C = UDV^T \Rightarrow U = D^{-1}VC$  ולכן  $U$  שווה ל-

$$\begin{aligned} U &= \begin{bmatrix} \frac{1}{\sqrt{80}} & 0 \\ 0 & \frac{1}{\sqrt{20}} \end{bmatrix} \begin{bmatrix} \sqrt{\frac{1}{10}} & \sqrt{\frac{9}{10}} \\ \sqrt{\frac{9}{10}} & -\sqrt{\frac{1}{10}} \end{bmatrix} \begin{bmatrix} 5 & 5 \\ -1 & 7 \end{bmatrix} = \\ &= \begin{bmatrix} \sqrt{\frac{1}{2}} & \sqrt{\frac{1}{2}} \\ \sqrt{\frac{1}{2}} & -\sqrt{\frac{1}{2}} \end{bmatrix} \end{aligned}$$

## 2.3 סעיף 7:

אלגוריתם למציאת מטריצת  $SVD$ . נסמן,  $C_0 = A^T A$ , ו- $v_1 \dots v_n, \lambda_1 \dots \lambda_n$  את הע"ע והו"ע של  $C_0$ . וב  $m = \operatorname{argmax} \{\lambda_i\}$  נראה את נכונות הטענה, כלומר שהסדרה  $b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} \xrightarrow{k \rightarrow \infty} v_m$  לכל תנאי התחלה עבורם  $b_{0_m} \neq 0$ . הוכחה לפי סעיף קודם נזכיר כי לפי התרגיל הקודם:  $C_0 = VD^2V^T$  כאשר  $V$  אורטונורמלית מכאן-

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{VD^2V^T b_k}{\|VD^2V^T b_k\|} = \frac{VD^2V^T \frac{VD^2V^T b_{k-1}}{\|VD^2V^T b_{k-1}\|}}{\|VD^2V^T \frac{VD^2V^T b_{k-1}}{\|VD^2V^T b_{k-1}\|}\|}$$

ניעזר בכך ש  $V$  אורטונורמלית ולכן  $V^T V = \mathbb{I}$ . בנוסף  $\|VD^2V^T b_{k-1}\| \in \mathbb{R}$  ולכן ניתן לצמצם את הפקטורים כי  $\|\alpha u\| = \alpha \|u\|$ . נקבל כי

$$b_{k+1} = \frac{VD^4V^T b_{k-1}}{\|VD^4V^T b_{k-1}\|}$$

ניפתח באופן איטרטיבי (אינדוקציה).

$$b_{k+1} = \frac{VD^{2k}V^T b_0}{\|VD^{2k}V^T b_0\|}$$

נפעיל כמה טריקים, אם  $b_0 \sim \mathcal{D}$  אז גם  $V^T b_0 \sim \mathcal{D}$  (כפל של גודל דטרמיננטי במשתנה מקרי משמר התפלגות). בנוסף מאורטונורמליות  $V$  משמרת נורמה, נסמן  $\tilde{b}_0 = V^T b_0$  וב-  $b_{k+1}^{(j)}$  את הקורדינטה  $j$  של  $b_{k+1}$ . ונצטמצם ל-

$$b_{k+1} = \frac{VD^{2k}\tilde{b}_0}{\|VD^{2k}\tilde{b}_0\|} = \frac{VD^{2k}\tilde{b}_0}{\|D^{2k}\tilde{b}_0\|}$$

$$\Rightarrow b_{k+1}^{(l)} = \sum_j V_{l,j} \frac{\lambda_j^k \tilde{b}_0^{(j)}}{\left(\sum_i^n \left(\lambda_i^k \tilde{b}_0^{(i)}\right)^2\right)^{\frac{1}{2}}} = \sum_j V_{l,j} \frac{\left[\frac{\lambda_j}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(j)}}{\tilde{b}_0^{(m)}}}{\left(1 + \sum_{i \neq m}^n \left(\left[\frac{\lambda_i}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(i)}}{\tilde{b}_0^{(m)}}\right)^2\right)^{\frac{1}{2}}}$$

כאשר ונקבל שלכל  $j \neq m$  הביטוי  $\left[\frac{\lambda_j}{\lambda_m}\right]^k \rightarrow 0$  ולכן  $b_{k+1}^{(l)} = V_{l,m}$  כלומר  $b_{k+1}$  שווה לעמודת  $m$  ב  $V$  וזאת בדיוק  $v_m$ . (כי  $V$  היא המטריצה המלכסנת את  $A^T A$ ) ■

שלב שני, **הורדת מימד**, נגדיל עכשיו וקטור חדש כאשר  $b_0^{(\tilde{m})} = 0$  ונשים לב כי  $\lambda_m^k b_0^{(\tilde{m})} = 0$ , מכאן נסמן ב'  $m'$  את הע"ע השני בגודלו ונקבל בדיוק באות הדרך כי  $b_{k+1}$  מתכנס ל  $v_{m'}$ . נמשיך באופן איטרטיבי ונמצא כך את  $V$ .  
מובן ש  $C_0 = VD^2V^T \Rightarrow V^T C_0 V = D^2$  ולכן מצאנו גם את  $D$ . ולבסוף נשתמש ב  $U = D^{-1}VC_0$  כדי למצוא את  $U$ .

**זמן ריצה:**

נחסום את  $\|b_k, v_m\|$ :

$$\|b_k, v_m\| = \left\| \sum_j V_{m,j} \frac{\left[\frac{\lambda_j}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(j)}}{\tilde{b}_0^{(m)}}}{\left(1 + \sum_{i \neq m}^n \left(\left[\frac{\lambda_i}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(i)}}{\tilde{b}_0^{(m)}}\right)^2\right)^{\frac{1}{2}}} - V_{m,j} \right\| \leq$$

$$\leq \left\| \sum_j V_{m,j} \left[\frac{\lambda_j}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(j)}}{\tilde{b}_0^{(m)}} - V_{m,j} \right\| \leq$$

$$\leq^* \sqrt{(n-1) \left( V_{m',j} \left[\frac{\lambda_{m'}}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(m')}}{\tilde{b}_0^{(m)}} \right)^2}$$

כאשר  $m'$  הוא האינדקס של הע"ע השני הכי גדול. \* כמובן שהאי-שיוון נכון אחל ממקום מסויים (צריך לבחור  $k$  מספיק גדול כדי לבטח שהפקטור  $\frac{\tilde{b}_0^{(m')}}{\tilde{b}_0^{(m)}}$   $V_{m',j}$  יחי יחסית לא משמעותי ביחס ל  $\left[\frac{\lambda_{m'}}{\lambda_m}\right]$ , אינפי 1). נמשיך:

$$\leq \sqrt{n} V_{m',j} \left[ \frac{\lambda_{m'}}{\lambda_m} \right]^k \frac{b_0^{(\tilde{m}')}}{b_0^{(\tilde{m})}} \leq \varepsilon$$

ולכן עבור דיוק של לפחות  $\varepsilon$  נדרוש :

$$k \geq \log_{\frac{\lambda_{m'}}{\lambda_m}} \left( \frac{b_0^{(\tilde{m})}}{b_0^{(\tilde{m}')} V_{m',j} \sqrt{n}} \varepsilon \right) = \log_{\frac{\lambda_{m'}}{\lambda_m}} \left( \frac{b_0^{(\tilde{m}')} V_{m',j} \sqrt{n}}{b_0^{(\tilde{m})} \varepsilon} \right) \geq$$

$$\log_{\frac{\lambda_{m'}}{\min \lambda}} \left( \frac{b_0^{(\tilde{m}')} V_{m',j} \sqrt{n}}{b_0^{(\tilde{m})} \varepsilon} \right) = \mathcal{O} \left( \ln \left( \frac{\sqrt{n}}{\varepsilon} \right) \right)$$

ההיפוך בסיסים ב  $\log$  היה חיוני מאחר ו-  $\frac{\lambda_{m'}}{\lambda_m} \leq 1$  בהצגה זאת אנחנו לא מרוויחים אינפורמציה אינטואיטיבית. נכחיש כרגע את ההשפעות של שגיאת  $\varepsilon$  על האיטרציות הבאות. חישוב  $b^{k+1}$  מ  $b^k$  דורש  $\mathcal{O}(n)$  עבודה (נשים לב שאת הסכום במכנה אנו מחשבים רק פעם אחת עבור כל הקורדינטות של  $b^{k+1}$ ), ולכן נבקבל שאת  $V$  ניתן לחשב ב  $\mathcal{O} \left( n^2 \ln \left( \frac{\sqrt{n}}{\varepsilon} \right) \right)$  את  $U$  ניתן לחשב באותו אופן, נפעיל את אותה וריאציה על  $AA^T = C_0^T$ .  $D$  מורכבת מ הע"מ של  $A$ , נעבור עמודה עמודה ב  $v_m \in V$  וניפתור את המשוואה  $Av_m = \lambda v_m$ , כאשר מספיק לנו לפתור רק עבור הקורדינטה הראשונה שאינה שווה ל-0 כלומר  $\lambda_m = \frac{\sum A_0^i v_m^i}{v_m^0}$  כלומר חישוב  $\lambda_m$  דורש  $\mathcal{O}(n)$  וחישוב  $D$  דורש  $\mathcal{O}(n^2)$  ולכן סך הכל נישאר עם זמן ריצה אסימפטוטי של  $\mathcal{O} \left( n^2 \ln \left( \frac{\sqrt{n}}{\varepsilon} \right) \right)$ .

### 3 חלק שלישי.

#### 3.1 סעיף 8:

יהיה  $x \in \mathbb{R}^n$  וקטור קבוע, ו  $U \in \mathbb{R}^{n \times n}$  אורטוגונלית. נחשב את היעקובן של

$$f(\sigma) = U \text{diag}(\sigma) U^T x$$

$$\Rightarrow f(\sigma)_i = U_i^j \sigma_j \delta_j^k (U^T)_k^l x_l = U_i^k \sigma_k (U^T)_k^l x_l$$

$$J(f)_{i,j} = \frac{\partial f_i}{\partial \sigma_j} = U_i^k \delta_{k,j} (U^T)_k^l x_l = U_i^j (U^T)_j^l x_l$$

נשים לב כי רק  $l$  אינדקס  $x$ , ולכן הכתיב שקול ל-  $J(f) = U \text{diag}(U^T x)$ .

#### 3.2 סעיף 9:

נתון  $h(\sigma) = \frac{1}{2} |f(\sigma) - y|^2$  נחשב את הגרדיאנט:

$$\nabla h_i = \frac{\partial h}{\partial \sigma_i} = \frac{\partial h}{\partial f} \frac{\partial f}{\partial \sigma_i} = (f(\sigma) - y) \frac{\partial f}{\partial \sigma_i} \Rightarrow \nabla h = (f(\sigma) - y)^T \nabla f$$

#### 3.3 סעיף 10:

נחשב את היעקוביאן של ה  $\text{softmax}$   $g(z)_j = \frac{e^{z_j}}{\sum e^{z_k}}$ :


$$J(g)_{i,j} = \frac{\partial g_i}{\partial z_j} = \frac{\delta_{i,j} e^{z_i} \sum e^{z_k} - e^{z_j} e^{z_i}}{(\sum e^{z_k})^2} = \frac{\delta_i^j e^{z_i} \sum e^{z_k}}{(\sum e^{z_k})^2} - \frac{e^{z_j} e^{z_i}}{(\sum e^{z_k})^2} =$$

$$= \delta_i^j g_i - g_i g_j = g_i (\delta_i^j - g_j)$$

## 4 חלק רביעי.

## 4.1 סעיף 11:

Normal distribution  $\sigma(x) = \sigma(y) = \sigma(z) = 1$  and  $\mu = 0$



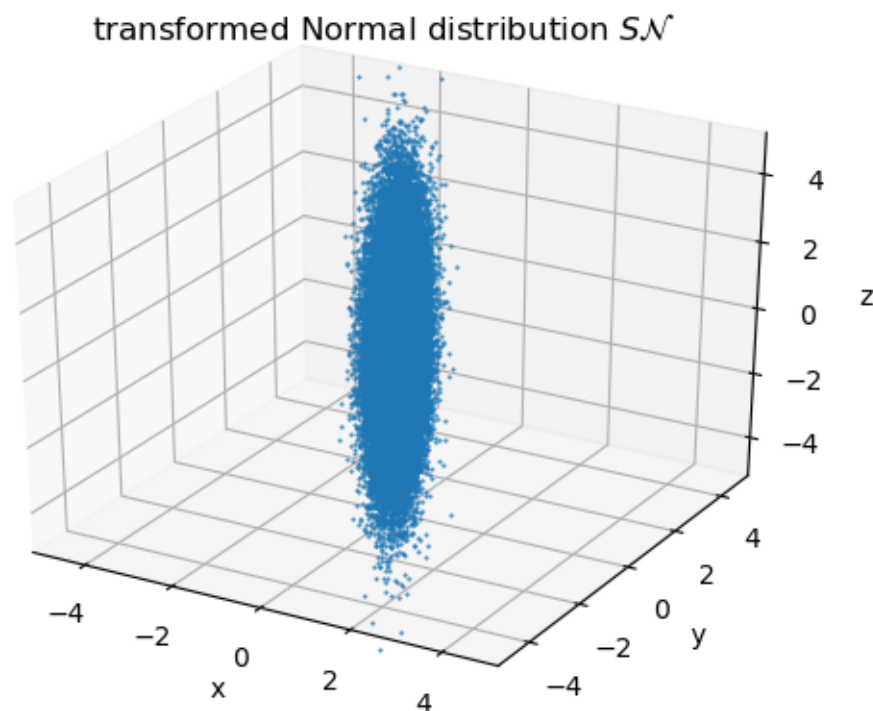
## 4.2 סעיף 12:

אנליטית: אנו יודעים כי  $cov(ax, y) = a \cdot cov(x, y)$  ולכן נצפה לקבל את  $S^2$  -  $cov_{i,i} = diag(S^2_{i,i}) \Rightarrow$  באופן נומרי מקבל את :

```
davidponar@DESKTOP-M43N0AS MSYS ~/workspace/iml/exercies/ex1 (master)
$ python ./3d_gaussian.py
[[1.00755762e-02 1.17976315e-03 2.67707751e-03]
 [1.17976315e-03 2.41934079e-01 1.53245781e-02]
 [2.67707751e-03 1.53245781e-02 3.99995184e+00]]

davidponar@DESKTOP-M43N0AS MSYS ~/workspace/iml/exercies/ex1 (master)
$ python ./3d_gaussian.py
[[ 1.00194739e-02  1.16457886e-04 -7.34568479e-04]
 [ 1.16457886e-04  2.51434529e-01 -3.21494511e-03]
 [-7.34568479e-04 -3.21494511e-03  4.03340142e+00]]
```

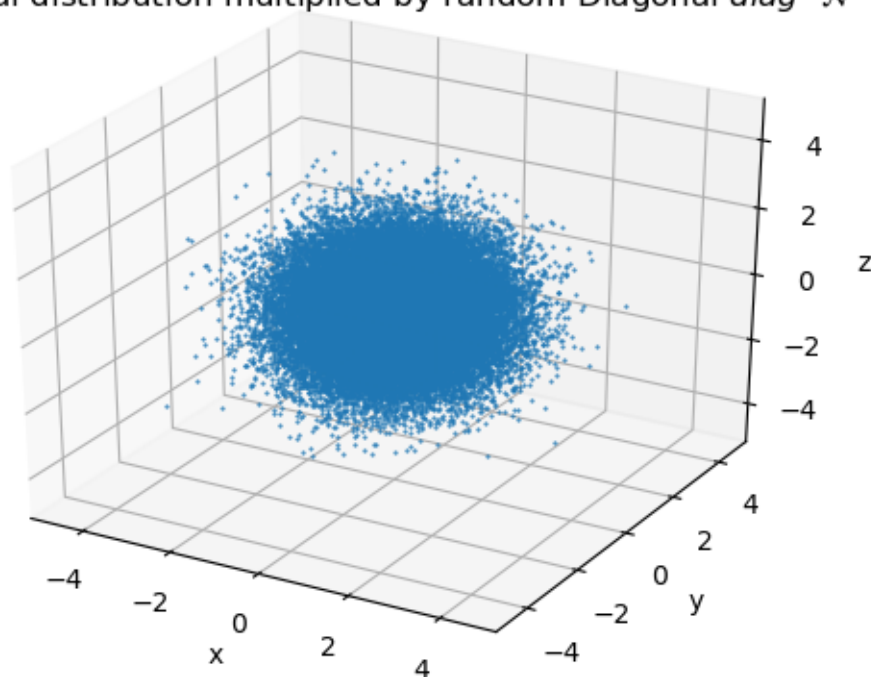
כאשר החישוב הראשון הוא ל  $n = 5 \cdot 10^3$  בעוד שהחישוב השני הוא ל  $n = 5 \cdot 10^4$  כלומר קל לראות שהמטריצה שואפת ל  $S^2$ . הנקודות עצמן :




### 4.3 סעיף 13 :

למעשה אנו מסובבים את הדאטה שלנו בזווית רנדומית. נמסן ב  $X$  את המידע, וב  $SX$  את המידע לאחר המתיחה. ל  $X$  הייתה סימטריה לסיבובים  $(x \sim y \sim z)$  ולכן נצפה שלאחר הסיבוב נקבל עדיין כי  $cov(RX) = cov(X)$ . לעומת זאת  $R(SX) = (RS)X$  ולכן נצפה לקבל סיבוב של המידע ומכאן גם סיבוב של ווקטור השונות, (עכשיו  $cov$  כבר לא תהיה אלכסון).

Normal distribution multiplied by random Diagonal  $diag \cdot \mathcal{N}$




transformed Normal distribution multiplied by random Diagonal  $diag \cdot S\mathcal{N}$




4.4 סעיף 14 :

היסטוגרמת ההטלה על ציר ה- $x$  :





היסטוגרמת ההטלה על ציר ה  $y$  :





## 4.5 סעיף 15 :

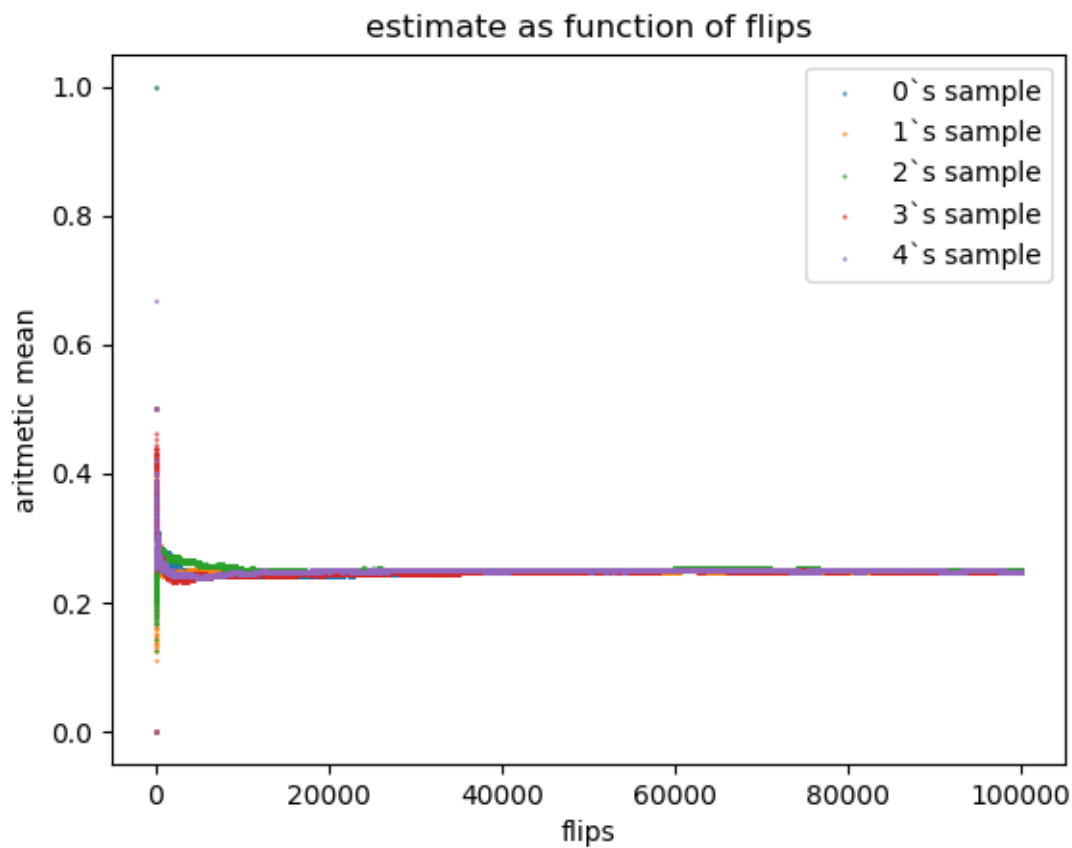
היסטוגרמת ההטלה על ציר ה- $x$  :Histogram of projection Normal distribution for  $z \in (-0.4, 0.1) \text{proj}(\text{data}, x)$ היסטוגרמת ההטלה על ציר ה- $y$  :Histogram of projection Normal distribution for  $z \in (-0.4, 0.1) \text{proj}(\text{data}, y)$ 

כאשר אובדן הצורה הגאוסנית, נובע מכך שהדאטה שלנו מכיל פחות נקדות כרגע, ולכן רגיש יותר לרעש.

## 5 חלק חמישי

## 5.1 סעיף 16 :

הממוצע הארמטי כפונקציה של מספר ההטלות עבור 5 הניסויים הראשונים, מאחר וההטלות מתפלגות  $i.i.d$  ניתן לראות התכנסות לתוחלת של מטבע יחיד :



## 5.2 16 סעיפים בוג :

נישתמש בתוצאה שעבור מטבע יחיד  $p(1-p) \leq \frac{1}{4}$  ולכן  $D^m[|p - \hat{p}| \geq \varepsilon] \leq \frac{1}{4m\varepsilon^2}$  וכמובן שהופנדינג מקיים:  $D^m[|p - \hat{p}| \geq \varepsilon] \leq 2e^{-2m\varepsilon^2}$  עבור  $\varepsilon$  הים השונים נצייר את החסם, ונשווה אל ההפרש האמיתי בין הממוצע האריטמי לבין התוחלת הצפויה :

