

Contents

1	./3d gaussian.py	2
2	./ex1.pdf	6

1 ./3d gaussian.py

```
1  import numpy as np
2  import pandas as pd
3  from plotnine import *
4  import matplotlib.pyplot as plt
5  from matplotlib import rc
6
7  from mpl_toolkits.mplot3d import Axes3D
8  from scipy.linalg import qr
9
10 # rc('text', usetex=True)
11 mean = [0, 0, 0]
12 cov = np.eye(3)
13 x_y_z = np.random.multivariate_normal(mean, cov, 50000).T
14
15
16 def get_orthogonal_matrix(dim):
17     H = np.random.randn(dim, dim)
18     Q, R = qr(H)
19     return Q
20
21
22 def plot_3d(x_y_z):
23     '''
24     plot points in 3D
25     :param x_y_z: the points. numpy array with shape: 3 X num_samples (first dimension for x, y, z
26     coordinate)
27     '''
28     fig = plt.figure()
29     ax = fig.add_subplot(111, projection='3d')
30     ax.scatter(x_y_z[0], x_y_z[1], x_y_z[2], s=1, marker='.', depthshade=False)
31     ax.set_xlim(-5, 5)
32     ax.set_ylim(-5, 5)
33     ax.set_zlim(-5, 5)
34     ax.set_xlabel('x')
35     ax.set_ylabel('y')
36     ax.set_zlabel('z')
37
38
39 def plot_2d(x_y):
40     '''
41     plot points in 2D
42     :param x_y_z: the points. numpy array with shape: 2 X num_samples (first dimension for x, y
43     coordinate)
44     '''
45     fig = plt.figure()
46     ax = fig.add_subplot(111)
47     ax.scatter(x_y[0], x_y[1], s=1, marker='.')
48     ax.set_xlim(-5, 5)
49     ax.set_ylim(-5, 5)
50     ax.set_xlabel('x')
51     ax.set_ylabel('y')
52
53
54 def section11():
55
56     plot_3d(x_y_z)
57     plt.title("Normal distribution $ \sigma(x) = \sigma(y) = \sigma(z) = 1 $ and $ \mu = 0 $")
58     plt.savefig("sec11.png")
59
```

```

60
61 def section12():
62     S = np.diag([0.1 , 0.5, 2])
63     S_transform = S.dot( x_y_z )
64     plot_3d( S_transform )
65     plt.title("transformed Normal distribution $ S \mathcal{N}$")
66     plt.savefig("sec12.png")
67
68
69     S_trandform_cov = np.cov(S_transform)
70     print( S_trandform_cov )
71
72
73 def section13():
74     S = np.diag([0.1 , 0.5, 2])
75     S_transform = S.dot( x_y_z )
76
77
78     rndmatrix = get_orthogonal_matrix( 3 )
79
80     S_trans_mul_by_orth =\
81         rndmatrix.dot( S_transform )
82
83     plot_3d( rndmatrix.dot( x_y_z ) )
84     plt.title("Normal distribution multiplied by random Diagonal $ diag \cdot \mathcal{N}$")
85     plt.savefig("sec13mulbyrand_orth.png")
86
87
88     plot_3d( S_trans_mul_by_orth )
89     plt.title("transformed Normal distribution multiplied by random Diagonal $ diag \cdot S \mathcal{N}$")
90     plt.savefig("sec13mulbyrand_orth_S.png")
91
92
93 def plot_xy_proj_histo(x_y_z, sec, _title):
94     #ploting 2d proj
95     plot_2d(x_y_z[:-1])
96     plt.savefig("{0}proj.png".format(sec))
97     # iterating over the x any y axes.
98     for X, _dim in zip(x_y_z[:-1] , ["x" , "y"]):
99         # calculate histogram
100         fig = plt.figure()
101         x , y = np.histogram( X, bins = 600 )
102         plt.plot( y[:-1], x,
103             label="histogram of {0} dim".format(_dim) )
104         plt.title(_title.format(_dim))
105         plt.xlabel(_dim)
106         plt.ylabel('points')
107         plt.savefig("{0}proj_hist_{1}.png".format(sec,_dim))
108
109 def section14():
110
111     plot_xy_proj_histo(x_y_z, "section14", "Histogram of projection Normal distribution $ proj( data , {0}) $")
112
113
114
115 def section15():
116
117     query = (x_y_z[2] >= -0.4) & (x_y_z[2] <= 0.1)
118     filtred = np.array( [ x_y_z[_] for _ in range(3) ]
119         ,dtype=np.float64)
120     print(filtred)
121     plot_xy_proj_histo( filtred, "section15", "Histogram of projection Normal distribution for $ z \in (-0.4,0.1) proj( data
122
123
124 def section16():
125     length = 10**5
126     samples = 1000
127     data = np.random.binomial(1, 0.25, (samples, length))

```

```

128     epsilon = [0.5, 0.25, 0.1, 0.01, 0.001]
129
130
131     plt.figure()
132
133     def plot_estimate_function_as_m(row , i):
134         '''
135             plotting the arithmetic mean of given sample.
136         '''
137         X, Y, _accsum = [0], [0], 0
138         for coin, value in enumerate(row):
139             if coin > 0 :
140                 _accsum += value
141                 X.append( coin )
142                 Y.append( _accsum / coin )
143
144         plt.scatter(X, Y, s=1, marker='.', label="{0}`s sample".format(i) )
145
146
147         # plt.title("{0}'s dataset'".format(i))
148         plt.xlabel("flips")
149         plt.ylabel("arithmetic mean")
150         for i in range(5):
151             plot_estimate_function_as_m( data[i], i)
152
153     plt.legend()
154     plt.title("estimate as function of flips" )
155     plt.savefig("section16a.png")
156
157     def bound_by_one(X ,Y):
158         '''
159             bound_by_one - assignment 1's at the greater values.
160         '''
161         Y [Y > 1] = 1
162         return X, Y
163
164     def hoffding(eps, length):
165         '''
166             estimate of the probability by Hoffding.
167         '''
168         X = np.arange(length)
169         return bound_by_one(X , 2* np.exp(-2*(X)*(eps**2)))
170
171     def chaviapprox(eps, length):
172         '''
173             estimate of the probability by Chebyshevs.
174         '''
175         X = np.arange(length)
176         return bound_by_one(X, 0.25 / ( X * eps**2))
177
178     def plottingseq_distance_from_bound(eps, length, data):
179         '''
180             calculate the amount of samples which their aritmatic mean is
181             greater than given epsilon.
182         '''
183         precentage = [ ]
184         for m in range(1,length+1):
185             count = 0
186             for sample in data:
187                 if ( abs(np.sum(sample[:m]) - 0.25*m) > eps*m):
188                     count += 1
189             precentage.append(count / samples)
190         return np.arange(length), precentage
191
192
193     relevantlength = [100 ,100 ,100 ,10**4 ,10**5 ]
194
195     funcnaems = [ "Chebyshevs" , "Hoffding" ]

```

```

196     for i, eps in enumerate( epsilon ):
197         if i == 4:
198             plt.figure()
199             for j, func in enumerate( [chaviapprox, hoffding] ):
200                 plt.scatter( *(func(eps, relevantlength[i] )),
201                             s=1, marker='.', label="{0}".format(funcnaems[j]))
202             plt.scatter(\
203                 *plotingseq_distance_from_bound(eps, relevantlength[i], data),\
204                 s=1, marker='.', label=" $ P( \overline{\{x\}} - E[x] > {0})$".format(eps))
205             plt.title("upper bound, $ \varepsilon = {0} $".format(eps))
206             plt.xlabel("flips")
207             plt.ylabel("probability bound")
208             plt.legend()
209             plt.savefig("section16b{0}.png".format(i))
210
211
212
213 if __name__ == "__main__":
214
215     section11()
216     section12()
217     section13()
218     section14()
219     section15()
220     section16()

```

תרגיל 1

7 באפריל 2020

דויד פונרובסקי 208504050

1 חימום.

1.1 סעיפים 1 + 2:

$$\begin{aligned} \text{proj}(u, v) &= \frac{\langle u, v \rangle}{\|u\|} \cdot \frac{u}{\|u\|} = \\ (1) \rightarrow & \frac{1}{1^2 + (-1)^2 + 2^2} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ -1 \\ 1 \\ 2 \end{bmatrix} \begin{bmatrix} 0 \\ -1 \\ 1 \\ 2 \end{bmatrix} = \frac{6}{9} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} \\ (2) \rightarrow & \frac{1}{1^2 + (-1)^2 + 1^2} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} = \frac{0}{3} \begin{bmatrix} 1 \\ 0 \\ 1 \\ -1 \end{bmatrix} = 0 \end{aligned}$$

1.2 סעיף 3:

טענה- $\langle u, v \rangle = 0 \Leftrightarrow$ הזווית בין u ל v היא $\pm \frac{\pi}{2}$. ל $u, v \in \mathbb{R}^m$. הוכחה, נחשב את $\langle u, v \rangle$:

$$0 = \langle u, v \rangle = \|u\| \cdot \|v\| \cos \theta$$

מיצד שני נתון כי $\vec{0} \neq u, v$ ולכן $\|u\|, \|v\| > 0$ זה יכל לקרות אם ורק אם $\cos \theta = 0$ ולכן $\theta = \pm \frac{\pi}{2}$ (עד כדי מחזור 2π).

1.3 סעיף 4:

טענה- אם $A \in \text{Orthonormal}$ אזי $\|Au\|_2 = \|u\|_2$. הוכחה: נזכיר כי $A^t A = \mathbb{I}$, ונקבל כי :

$$\|Au\|_2 = \left((Au)^t Au \right)^{\frac{1}{2}} = \left(u^t A^t Au \right)^{\frac{1}{2}} = \left(u^t u \right)^{\frac{1}{2}} = \|u\|_2$$

: SVD 2

2.1 סעיף 5:

נתונה לנו A ביצוג SVD כלומר $A = UDV^T$ כאשר U ו V הן אורטונורמליות. לכן נקבל כי $A^{-1} = (UDV^T)^{-1} = (V^T)^{-1} D^{-1} U^{-1} = V D^{-1} U^T$. כשאשר המעבר האחרון $U^{-1} = U^T$ נובע מכך ש U אורטונורמלית (לפי משפט). נשים לב שחישוב ההופכית על ידי דירוג $[A|\mathbb{I}]$ (גאוס-ג'ורדן) ידרוש מאיתנו $\mathcal{O}(n^3)$ זמן, כאשר n הוא מספר השורות (והעמודות) של A . לעומת זאת מאחר ו $D \in diag$ ניתן לחשב את D^{-1} ב $\mathcal{O}(n)$ ואת U^T ניתן לחשב ב $\mathcal{O}(n^2)$. את המימוש של U^T ניתן לשפר בכך שבמקום להחליף את U ניתן פשוט להחליף את האיטרטור, כך שבעת גישה ל $(U^T)_{i,j}$ נקבל את $U_{j,i}$. זאת כמובן ב $\mathcal{O}(1)$.

2.2 סעיף 6:

נשים לב כי $C^T = (UDV^T)^T = VD^T U^T = VD^2 V^T$ אבל $D \in diag$ ולכן $D^T = D$ כלומר $D^T = D$ כלומר $C^T = VDU^T UDV^T = VD^2 V^T$. מכאן נקבל כי $C^T C = VD^2 V^T$. כלומר נוכל למצוא את D ו V על ידי ליכסון של $C^T C$.

$$C^T C = \begin{bmatrix} 5 & -1 \\ 5 & 7 \end{bmatrix} \begin{bmatrix} 5 & 5 \\ -1 & 7 \end{bmatrix} = \begin{bmatrix} 26 & 18 \\ 18 & 74 \end{bmatrix}$$

נמצא את הערכים העצמאים:

$$\det(C^T C - \lambda \mathbb{I}) = 0 \Rightarrow (26 - \lambda)(74 - \lambda) - 18^2 = 0$$

פיתרונות של המשוואה שלעיל הם: $\lambda = 20, 80$ ולכן $D^2 = \begin{bmatrix} 80 & 0 \\ 0 & 20 \end{bmatrix}$ כלומר $D = \begin{bmatrix} \sqrt{80} & 0 \\ 0 & \sqrt{20} \end{bmatrix}$. נמצא את הוקטורים העצמאים:

$$\begin{aligned} \begin{bmatrix} 26 - 20 & 18 \\ 18 & 74 - 20 \end{bmatrix} &= \begin{bmatrix} 6 & 18 \\ 18 & 54 \end{bmatrix} = 6 \begin{bmatrix} 1 & 3 \\ 3 & 9 \end{bmatrix} \Rightarrow v = \text{normfactor} \cdot \begin{bmatrix} 3 \\ -1 \end{bmatrix} \\ \begin{bmatrix} 26 - 80 & 18 \\ 18 & 74 - 80 \end{bmatrix} &= \begin{bmatrix} -54 & 18 \\ 18 & -6 \end{bmatrix} = 6 \begin{bmatrix} -9 & 3 \\ 3 & -1 \end{bmatrix} \Rightarrow v = \text{normfactor} \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} \\ V^T &= \text{normfactor} \cdot \begin{bmatrix} 1 & 3 \\ 3 & -1 \end{bmatrix} = \begin{bmatrix} \sqrt{\frac{1}{10}} & \sqrt{\frac{9}{10}} \\ \sqrt{\frac{9}{10}} & -\sqrt{\frac{1}{10}} \end{bmatrix} \end{aligned}$$

בנוסף אנו יודעים כי $C = UDV^T \Rightarrow U = D^{-1}VC$ ולכן U שווה ל-

$$\begin{aligned} U &= \begin{bmatrix} \frac{1}{\sqrt{80}} & 0 \\ 0 & \frac{1}{\sqrt{20}} \end{bmatrix} \begin{bmatrix} \sqrt{\frac{1}{10}} & \sqrt{\frac{9}{10}} \\ \sqrt{\frac{9}{10}} & -\sqrt{\frac{1}{10}} \end{bmatrix} \begin{bmatrix} 5 & 5 \\ -1 & 7 \end{bmatrix} = \\ &= \begin{bmatrix} \sqrt{\frac{1}{2}} & \sqrt{\frac{1}{2}} \\ \sqrt{\frac{1}{2}} & -\sqrt{\frac{1}{2}} \end{bmatrix} \end{aligned}$$

2.3 סעיף 7:

אלגוריתם למציאת מטריצת SVD . נסמן, $C_0 = A^T A$, ו- $v_1 \dots v_n, \lambda_1 \dots \lambda_n$ את הע"ע והו"ע של C_0 . וב $m = \operatorname{argmax} \{\lambda_i\}$ נראה את נכונות הטענה, כלומר שהסדרה $b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} \xrightarrow{k \rightarrow \infty} v_m$ לכל תנאי התחלה עבורם $b_{0_m} \neq 0$. הוכחה לפי סעיף קודם נזכיר כי לפי התרגיל הקודם: $C_0 = VD^2V^T$ כאשר V אורטונורמלית מכאן-

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{VD^2V^T b_k}{\|VD^2V^T b_k\|} = \frac{VD^2V^T \frac{VD^2V^T b_{k-1}}{\|VD^2V^T b_{k-1}\|}}{\|VD^2V^T \frac{VD^2V^T b_{k-1}}{\|VD^2V^T b_{k-1}\|}\|}$$

ניעזר בכך ש V אורטונורמלית ולכן $V^T V = \mathbb{I}$. בנוסף $\|VD^2V^T b_{k-1}\| \in \mathbb{R}$ ולכן ניתן לצמצם את הפקטורים כי $\|\alpha u\| = \alpha \|u\|$. נקבל כי

$$b_{k+1} = \frac{VD^4V^T b_{k-1}}{\|VD^4V^T b_{k-1}\|}$$

ניפתח באופן איטרטיבי (אינדוקציה).

$$b_{k+1} = \frac{VD^{2k}V^T b_0}{\|VD^{2k}V^T b_0\|}$$

נפעיל כמה טריקים, אם $b_0 \sim \mathcal{D}$ אז גם $V^T b_0 \sim \mathcal{D}$ (כפל של גודל דטרמיננטי במשתנה מקרי משמר התפלגות). בנוסף מאורטונורמליות V משמרת נורמה, נסמן $\tilde{b}_0 = V^T b_0$ וב- $b_{k+1}^{(j)}$ את הקורדינטה j של b_{k+1} . ונצטמצם ל-

$$b_{k+1} = \frac{VD^{2k}\tilde{b}_0}{\|VD^{2k}\tilde{b}_0\|} = \frac{VD^{2k}\tilde{b}_0}{\|D^{2k}\tilde{b}_0\|}$$

$$\Rightarrow b_{k+1}^{(l)} = \sum_j V_{l,j} \frac{\lambda_j^k \tilde{b}_0^{(j)}}{\left(\sum_i^n \left(\lambda_i^k \tilde{b}_0^{(i)}\right)^2\right)^{\frac{1}{2}}} = \sum_j V_{l,j} \frac{\left[\frac{\lambda_j}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(j)}}{\tilde{b}_0^{(m)}}}{\left(1 + \sum_{i \neq m}^n \left(\left[\frac{\lambda_i}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(i)}}{\tilde{b}_0^{(m)}}\right)^2\right)^{\frac{1}{2}}}$$

כאשר ונקבל שלכל $j \neq m$ הביטוי $\left[\frac{\lambda_j}{\lambda_m}\right]^k \rightarrow 0$ ולכן $b_{k+1}^{(l)} = V_{l,m}$ כלומר b_{k+1} שווה לעמודת m ב V וזאת בדיוק v_m . (כי V היא המטריצה המלכסנת את $A^T A$)

שלב שני, **הורדת מימד**, נגדיל עכשיו וקטור חדש כאשר $b_0^{(\tilde{m})} = 0$ ונשים לב כי $\lambda_m^k b_0^{(\tilde{m})} = 0$, מכאן נסמן m' את הע"ע השני בגודלו ונקבל בדיוק באות הדרך כי b_{k+1} מתכנס ל $v_{m'}$. נמשיך באופן איטרטיבי ונמצא כך את V .
 כמובן ש $C_0 = VD^2V^T \Rightarrow V^T C_0 V = D^2$ ולכן מצאנו גם את D . ולבסוף נשתמש ב $U = D^{-1}VC_0$ כדי למצוא את U .

זמן ריצה:

נחסום את $\|b_k, v_m\|$:

$$\|b_k, v_m\| = \left\| \sum_j V_{m,j} \frac{\left[\frac{\lambda_j}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(j)}}{\tilde{b}_0^{(m)}}}{\left(1 + \sum_{i \neq m}^n \left(\left[\frac{\lambda_i}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(i)}}{\tilde{b}_0^{(m)}}\right)^2\right)^{\frac{1}{2}}} - V_{m,j} \right\| \leq$$

$$\leq \left\| \sum_j V_{m,j} \left[\frac{\lambda_j}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(j)}}{\tilde{b}_0^{(m)}} - V_{m,j} \right\| \leq$$

$$\leq^* \sqrt{(n-1) \left(V_{m',j} \left[\frac{\lambda_{m'}}{\lambda_m}\right]^k \frac{\tilde{b}_0^{(m')}}{\tilde{b}_0^{(m)}} \right)^2}$$

כאשר m' הוא האינדקס של הע"ע השני הכי גדול. * כמובן שהאי-שיוון נכון אחל ממקום מסויים (צריך לבחור k מספיק גדול כדי לבטח שהפקטור $\frac{\tilde{b}_0^{(m')}}{\tilde{b}_0^{(m)}}$ $V_{m',j}$ יחי יחסית לא משמעותי ביחס ל $\left[\frac{\lambda_{m'}}{\lambda_m}\right]$, אינפיי 1). נמשיך:

$$\leq \sqrt{n} V_{m',j} \left[\frac{\lambda_{m'}}{\lambda_m} \right]^k \frac{b_0^{(\tilde{m}')}}{b_0^{(\tilde{m})}} \leq \varepsilon$$

ולכן עבור דיוק של לפחות ε נידרוש :

$$k \geq \log_{\frac{\lambda_{m'}}{\lambda_m}} \left(\frac{b_0^{(\tilde{m})}}{b_0^{(\tilde{m}')} V_{m',j} \sqrt{n}} \varepsilon \right) = \log_{\frac{\lambda_{m'}}{\lambda_m}} \left(\frac{b_0^{(\tilde{m}')} V_{m',j} \sqrt{n}}{b_0^{(\tilde{m})} \varepsilon} \right) \geq$$

$$\log_{\frac{\lambda_{m'}}{\min \lambda}} \left(\frac{b_0^{(\tilde{m}')} V_{m',j} \sqrt{n}}{b_0^{(\tilde{m})} \varepsilon} \right) = \mathcal{O} \left(\ln \left(\frac{\sqrt{n}}{\varepsilon} \right) \right)$$

ההיפוך בסיסים ב \log היה חיוני מאחר ו- $\frac{\lambda_{m'}}{\lambda_m} \leq 1$ בהצגה זאת אנחנו לא מרוויחים אינפורמציה אינטואיטיבית. נכחיש כרגע את ההשפעות של שגיאת ε על האיטרציות הבאות. חישוב b^{k+1} מ b^k דורש $\mathcal{O}(n)$ עבודה (נשים לב שאת הסכום במכנה אנו מחשבים רק פעם אחת עבור כל הקורדינטות של b^{k+1}), ולכן נבקבל שאת V ניתן לחשב ב $\mathcal{O} \left(n^2 \ln \left(\frac{\sqrt{n}}{\varepsilon} \right) \right)$ את U ניתן לחשב באותו אופן, נפעיל את אותה וריאציה על $AA^T = C_0^T$. D מורכבת מ הע"מ של A , נעבור עמודה עמודה ב $v_m \in V$ וניפתור את המשווה $Av_m = \lambda v_m$, כאשר מספיק לנו לפתור רק עבור הקורדינטה הראשונה שאינה שווה ל-0 כלומר $\lambda_m = \frac{\sum A_0^i v_m^i}{v_m^0}$ כלומר חישוב λ_m דורש $\mathcal{O}(n)$ וחשוב D דורש $\mathcal{O}(n^2)$ ולכן סך הכל נישאר עם זמן ריצה אסימפטוטי של $\mathcal{O} \left(n^2 \ln \left(\frac{\sqrt{n}}{\varepsilon} \right) \right)$.

3 חלק שלישי.

3.1 סעיף 8:

יהיה $x \in \mathbb{R}^n$ וקטור קבוע, ו $U \in \mathbb{R}^{n \times n}$ אורטוגונלית. נחשב את היעקובן של

$$f(\sigma) = U \text{diag}(\sigma) U^T x$$

$$\Rightarrow f(\sigma)_i = U_i^j \sigma_j \delta_j^k (U^T)_k^l x_l = U_i^k \sigma_k (U^T)_k^l x_l$$

$$J(f)_{i,j} = \frac{\partial f_i}{\partial \sigma_j} = U_i^k \delta_{k,j} (U^T)_k^l x_l = U_i^j (U^T)_j^l x_l$$

נשים לב כי רק l אינדקס x , ולכן הכתיב שקול ל- $J(f) = U \text{diag}(U^T x)$.

3.2 סעיף 9:

נתון $h(\sigma) = \frac{1}{2} |f(\sigma) - y|^2$ נחשב את הגרדיאנט:

$$\nabla h_i = \frac{\partial h}{\partial \sigma_i} = \frac{\partial h}{\partial f} \frac{\partial f}{\partial \sigma_i} = (f(\sigma) - y) \frac{\partial f}{\partial \sigma_i} \Rightarrow \nabla h = (f(\sigma) - y)^T \nabla f$$

3.3 סעיף 10:

נחשב את היעקוביאן של ה softmax : $g(z)_j = \frac{e^{z_j}}{\sum e^{z_k}}$


$$J(g)_{i,j} = \frac{\partial g_i}{\partial z_j} = \frac{\delta_{i,j} e^{z_i} \sum e^{z_k} - e^{z_j} e^{z_i}}{(\sum e^{z_k})^2} = \frac{\delta_i^j e^{z_i} \sum e^{z_k}}{(\sum e^{z_k})^2} - \frac{e^{z_j} e^{z_i}}{(\sum e^{z_k})^2} =$$

$$= \delta_i^j g_i - g_i g_j = g_i (\delta_i^j - g_j)$$

4 חלק רביעי.

4.1 סעיף 11:

Normal distribution $\sigma(x) = \sigma(y) = \sigma(z) = 1$ and $\mu = 0$




4.2 סעיף 12:

אנליטית: אנו יודעים כי $cov(ax, y) = a \cdot cov(x, y)$ ולכן נצפה לקבל את S^2 - $cov_{i,i} = diag(S^2_{i,i}) \Rightarrow$ באופן נומרי מקבל את :

```
davidponar@DESKTOP-M43N0AS MSYS ~/workspace/iml/exercies/ex1 (master)
$ python ./3d_gaussian.py
[[1.00755762e-02 1.17976315e-03 2.67707751e-03]
 [1.17976315e-03 2.41934079e-01 1.53245781e-02]
 [2.67707751e-03 1.53245781e-02 3.99995184e+00]]

davidponar@DESKTOP-M43N0AS MSYS ~/workspace/iml/exercies/ex1 (master)
$ python ./3d_gaussian.py
[[ 1.00194739e-02  1.16457886e-04 -7.34568479e-04]
 [ 1.16457886e-04  2.51434529e-01 -3.21494511e-03]
 [-7.34568479e-04 -3.21494511e-03  4.03340142e+00]]
```


כאשר החישוב הראשון הוא ל $n = 5 \cdot 10^3$ בעוד שהחישוב השני הוא ל $n = 5 \cdot 10^4$ כלומר קל לראות שהמטריצה שואפת ל S^2 . הנקודות עצמן :




4.3 סעיף 13 :

למעשה אנו מסובבים את הדאטה שלנו בזווית רנדומית. נמסן ב X את המידע, וב SX את המידע לאחר המתיחה. ל X הייתה סימטריה לסיבובים $(x \sim y \sim z)$ ולכן נצפה שלאחר הסיבוב נקבל עדיין כי $cov(RX) = cov(X)$. לעומת זאת $R(SX) = (RS)X$ ולכן נצפה לקבל סיבוב של המידע ומכאן גם סיבוב של ווקטור השונות, (עכשיו cov כבר לא תהיה אלכסון).

Normal distribution multiplied by random Diagonal $diag \cdot \mathcal{N}$




transformed Normal distribution multiplied by random Diagonal $diag \cdot S\mathcal{N}$

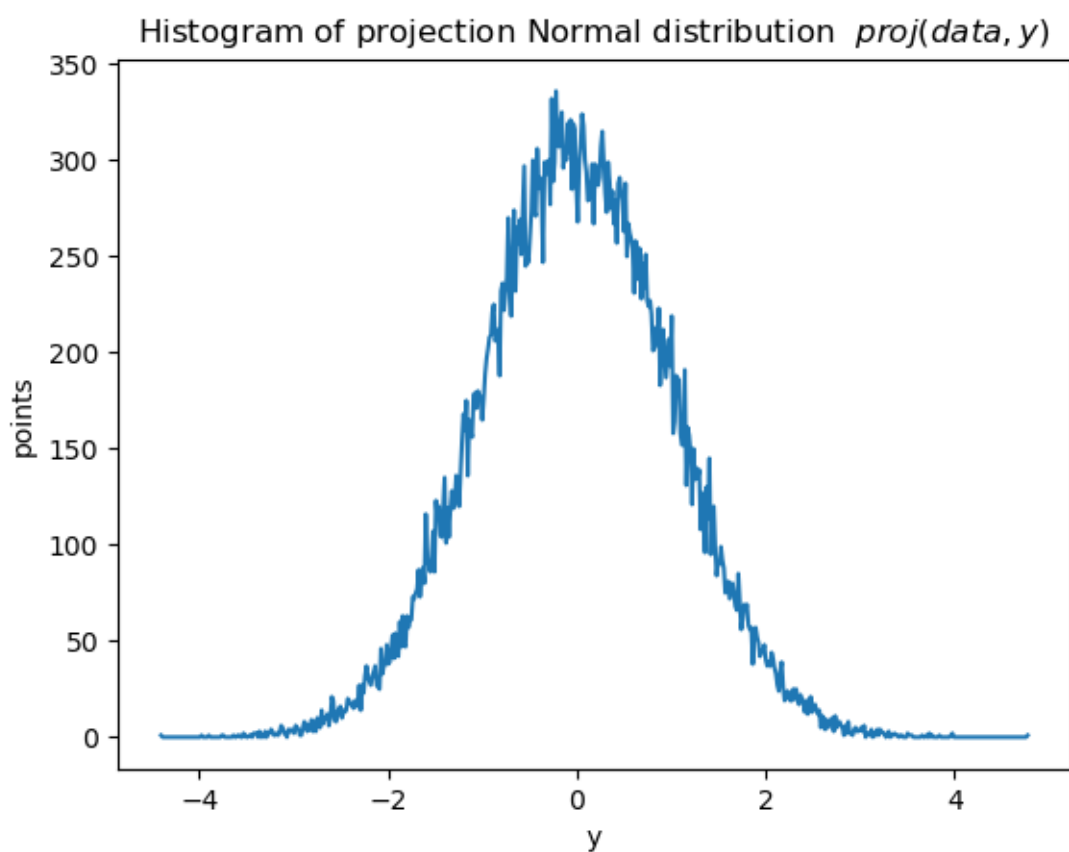


4.4 סעיף 14 :



היסטוגרמת ההטלה על ציר ה- x :



היסטוגרמת ההטלה על ציר ה y :



4.5 סעיף 15 :


היסטוגרמת ההטלה על ציר ה- x :Histogram of projection Normal distribution for $z \in (-0.4, 0.1) \text{proj}(\text{data}, x)$ היסטוגרמת ההטלה על ציר ה- y :Histogram of projection Normal distribution for $z \in (-0.4, 0.1) \text{proj}(\text{data}, y)$ 

כאשר אובדן הצורה הגאוסנית, נובע מכך שהדאטה שלנו מכיל פחות נקדות כרגע, ולכן רגיש יותר לרעש.

5 חלק חמישי

5.1 סעיף 16 :

הממוצע הארמטי כפונקציה של מספר ההטלות עבור 5 הניסויים הראשונים, מאחר וההטלות מתפלגות $i.i.d$ ניתן לראות התכנסות לתוחלת של מטבע יחיד :



5.2 16 סעיפים בוג :

נישתמש בתוצאה שעבור מטבע יחיד $p(1-p) \leq \frac{1}{4}$ ולכן $D^m[|p - \hat{p}| \geq \epsilon] \leq \frac{1}{4m\epsilon^2}$ וכמובן שהופנדינג מקיים: $D^m[|p - \hat{p}| \geq \epsilon] \leq 2e^{-2m\epsilon^2}$ עבור ϵ הים השונים נצייר את החסם, ונשווה אל ההפרש האמיתי בין הממוצע האריטמי לבין התוחלת הצפויה :

